

抗体物性予測モデルの転移学習

23MM345 佐々木 健太郎

埼玉大学大学院 理工学研究科 情報工学PG 松永研究室

研究背景


● タンパク質について

- タンパク質は20種類のアミノ酸から成り立つ
- アミノ酸の並び方によって、その機能と構造が定められる

● 研究課題

- 抗体は治療薬としての重要性が高いが、従来の抗体開発プロセスは手間がかかり、限界がある
- 昨今の機械学習・AIの進展によるインシリコ（コンピュータで行う）研究開発は、効率的かつ経済的なため、次世代抗体開発の鍵と期待されている

タンパク質配列



引用： <https://courses.lumenlearning.com/atd-herkimer-nutrition/chapter/2-21-amino-acids/>

対応関係

抗体の立体構造





PDBより引用

VHH抗体とは

● ラクダ科動物由来の抗体

- 軽鎖を伴わず重鎖のみで構成[1]
- 構造が安定で抗原への結合性に優れている
- 従来の抗体に比べて小型
- タンパク質工学的に取り扱いやすく、様々な医療応用が期待されている。



[1]M. Dumoulin, K. Conrath, A. Van Meirhaeghe, F. Meersman, K. Heremans, L.G.J. Frenken, S. Muyldermans, L. Wyns, A. Matagne, "Single-domain antibody fragments with high conformational stability", *Protein Sci.*, **11**, 500-515 (2002).

VHH抗体の熱安定性予測


● 背景

- VHH抗体は様々な環境要因（主に温度上昇）で構造が壊れてしまう（転移温度 T_m ）と抗体としての機能を失う。したがって熱に対する構造安定性の高いVHH抗体を設計, 探索することは創薬応用において重要
- 転移温度は実験で測定できるが、多数の変異体を網羅的に調べるにはコストと時間が多い。
- そこで機械学習モデルを使ったアプローチが求められる



● 学習概要


- タンパク質言語モデルESM-2を特徴量に用いて回帰学習を行うモデル
- 学習データ：VHH抗体の転移温度の実験値のデータベースであるNbThermoから、（配列、融解温度）のデータセットを約500点使用



シミュレーションデータを用いた転移学習

- 実験データは依然として少なくより精度を高めたい。
- そこでシミュレーションで計算された $\Delta \Delta G$ という熱安定性の指標データを学習に組み込むことで学習データを増やし予測精度をさらに向上させることを試みた。

$\Delta\Delta G$: アミノ酸配列の熱に対する安定性の指標




解析的に求めるのが難しい ΔG の代わりに、アミノ酸変異による
相対的な熱安定性の変化を定量化した物性量

マルチタスク学習

- $\Delta \Delta G$ はシミュレーションデータであり T_m そのものでもないため実験 T_m データと混ぜて学習を行うことは避けたい。
- そこでマルチタスク学習を行うで二つの異なる種類のデータを学習に組み込んだ。


● 学習概要

- タンパク質言語モデルESM-2を特徴量に用いて回帰学習を行うモデル
- 学習データ：NbThermo+ $\Delta \Delta G$
- 予測ヘッドを二つに分けることで共通の特徴表現を活用しつつ、両タスクに特化した学習を行う




● 学習設定

- NbThermoから56個のデータをランダムに抽出し8:2で訓練:テストデータに分割
- シミュレーションデータはMDで計算した $\Delta\Delta G$ とrosettaソフトウェアで計算した $\Delta\Delta G$ をそれぞれ、227,454,681,908個、219,438,657,876 個用いてマルチタスク学習を行なった
- 上記のそれぞれの条件とシミュレーションデータを使用しない条件でseed値を変更し100回試行して平均MAE(平均絶対誤差)を求め比較した



Performance Improvement through Multitask Learning



マルチタスク学習を導入することで予測精度（MAE）が向上し、さらにシミュレーションデータが増えるにより向上する傾向が見られた。

まとめと展望

● まとめ


- VHH抗体のTm予測精度を向上させるために、シミュレーションデータを使ったマルチタスクモデルを作成した
- 実際にシミュレーションデータを学習させることで精度が向上した

● 展望

- よりシミュレーションデータを増やしたマルチタスク学習を行うことで詳細なスケーリング則を検証したい

付録

a



マルチタスク学習を導入することで予測精度（MAE）が向上し、さらにシミュレーションデータが増えるにより向上する